Batería de preguntas para la defensa de la tesis

Estimación de estados en la tolva de un chancador primario

Daniel Alejandro Prado Correa — Documento de preparación personal

Cómo usar este documento. Las respuestas son modelos para entender el argumento, no guiones para memorizar. La comisión va a notar si una respuesta se recita. Lo que conviene memorizar son las cifras de la Sección 1 y la idea central de cada respuesta. Para cada pregunta, intente responder en voz alta antes de leer la respuesta.

1. Cifras que conviene saber

Reducción del RMSE del volumen frente a la medición cruda	+74,7 %
Frente a la media móvil	+53,6 %
Frente a la regresión local: diferencia media (no significativa)	−3,4 % [−7,1; +0,8]
Frente a la regresión local: corridas en que gana el filtro	72 %
Corridas sin vaciado (66): reducción / corridas ganadas	+10,4 % / 98 %
Corridas con vaciado (34): reducción	−17,8 %
Las mismas corridas sin saturación (ablación E2c): reducción / ganadas	+9,6 % / 97 %
Filtro calibrado como las líneas base ($3q_e$): reducción / ganadas	+5,3 % / 99 %
Tasa de extracción frente a diferencias finitas	+99,4 %
NEES sin vaciado / con vaciado (esperado: 2)	1,94 / 36,1
Memoria del filtro en régimen	65,8 s
ω_n numérico / analítico	0,02148 / 0,02148 rad/s
ζ numérico / analítico	0,7071 / $1/\sqrt{2}$
Asentamiento ante el cambio de dureza, filtro / regresión local	208 / 96 s
Pruebas de verificación superadas	8 de 8

2. Planteamiento y alcance

P1. ¿Cuál es exactamente el problema? ¿Por qué no basta con comprar un mejor sensor?

→ El problema es reconstruir dos variables: el volumen, que se mide mal, y la tasa de extracción, que no se mide. Un mejor sensor reduciría el ruido del volumen, pero la tasa seguiría sin medirse, y la superficie de la pila de roca seguiría siendo irregular: el error relevante no es la precisión del instrumento, sino la diferencia entre la cota que mide y el volumen real. El estimador usa el balance de masa para reconstruir la tasa a partir de cómo cambia el volumen.

P2. ¿Esto es un gemelo digital?

→ No. En la clasificación de Kritzinger et al., es un modelo digital de un componente, porque no tiene flujo automático de datos con ninguna planta. Sería parte de una sombra digital si recibiera datos del SCADA automáticamente (la interfaz en línea lo permite), y parte de un gemelo si además sus estimaciones volvieran automáticamente a la operación. «Gemelo digital» en el título es el marco en que se integraría, no lo que construí.

P3. ¿Qué demuestra y qué no demuestra su tesis?

→ Aporta evidencia de que la implementación es correcta (ocho pruebas de verificación) y muestra cómo se comporta el filtro bajo modelos declarados, con discrepancias controladas. No demuestra desempeño en una planta, ni que los parámetros representen una tolva real, ni beneficios operacionales. Esa separación está en la Sección 1.6 y en la 7.10 («Lo que esta tesis no demuestra»).

3. Diseño metodológico

P4. Si los datos los generó el mismo modelo que usa el filtro, ¿no es el filtro óptimo por construcción?

→ En el anteproyecto, sí: esa era su debilidad principal, y por eso esta tesis separa el proceso simulado del modelo del filtro. Hay un solo experimento en que coinciden a propósito, la verificación EV, y ahí la optimalidad por construcción es justamente lo que se quiere: si el código es correcto, tiene que cumplir las propiedades teóricas (ganancia igual a la solución de Riccati; NEES y NIS promedio en sus bandas en la gran mayoría de los pasos: con lotes independientes, el criterio del NEES falló por azar en el 11 % de ellos). En los experimentos E1 a E4, el proceso se aparta del filtro: la extracción vuelve a su nominal en vez de ser una caminata aleatoria, se satura cuando la tolva se vacía, el volumen está acotado y el sensor puede tener errores que el filtro no modela. La evidencia de que ya no es óptimo es que otra sintonía tiene menor error ($3q_e$, en E2b y E3a) y que la regresión local lo supera en las corridas con vaciado. Aparte, el NEES medio de 13,5, en vez de 2, muestra que su covarianza tampoco es consistente.

Ojo: el NEES prueba consistencia, no optimalidad: no lo use como prueba de que el filtro dejó de ser óptimo. Y no confunda esta objeción con «el filtro ve la verdad». El filtro nunca ve la verdad; la pregunta es si el mundo simulado se comporta como su modelo. Y reconozca la información privilegiada del filtro: su R y su q_e son los parámetros verdaderos del sensor y de la parte suave del proceso.

P5. ¿De dónde salen los parámetros?

→ Son supuestos de diseño, declarados como tales. Elegí órdenes de magnitud coherentes con una estación de chancado de gran capacidad: una carga de 180 m^3, una extracción de 0,8 m^3/s, una tolva de 450 m^3. No los tomé de una planta ni de la literatura, porque no encontré fuentes con esos valores para una tolva de chancado. Como el ruido del sensor es el más incierto, el Experimento E1 lo recorre de 2 a 40 m^3.

P6. ¿Por qué $\sigma_v = 10\,m^3$ si un radar tiene precisión de milímetros?

→ Porque el sensor mide la distancia a un punto de una superficie de roca irregular, que cambia con cada descarga. Convertir esa cota en volumen supone una superficie plana. Con unos 75 m^2 de sección, ±0,13 m de incertidumbre en la cota efectiva son unos 10 m^3. Es un argumento, no una medición; por eso el valor se recorre en E1.

P7. ¿Por qué comparar con una regresión local y no solo con la medición cruda?

→ Porque comparar con la medición cruda es fácil de ganar. La auditoría del anteproyecto mostró que su línea base ignoraba la descarga conocida de los camiones, lo que inflaba la ventaja del filtro. La regresión local usa la misma información que el filtro (balance de masa y descarga) y además se calibra con la verdad. Es el competidor exigente. La medición cruda y la media móvil no usan la descarga: la ventaja frente a ellas incluye el valor de esa información y no mide solo el modelo dinámico.

P8. ¿No es injusto calibrar las líneas base con la verdad? ¿Y el filtro?

→ Ninguno de los dos está en condiciones de planta. Las líneas base eligen su ventana con la verdad; el filtro usa los parámetros verdaderos del sensor y de la variación suave de la dureza. Para comparar con el mismo privilegio, en E2b elegí la sintonía del filtro en las mismas corridas de calibración que las ventanas: así el filtro gana en el volumen en el 99 % de las corridas.

Ojo: la objeción previsible es que en E2b el filtro conserva el R verdadero. Respuesta: el filtro calibrado ajusta un solo parámetro, el factor sobre q_e, como la regresión local ajusta su ventana; y como la estimación depende solo del cociente q_e/R (prueba G), el valor de R no le da información adicional sobre el error: solo fija la escala del NIS y del NEES. Reconozca también que solo 4 de las 30 corridas de calibración tuvieron vaciado.

P9. Separar las corridas con y sin vaciado después de ver los resultados, ¿no es buscar el resultado que conviene?

→ Por eso está declarado como exploratorio. Cuatro cosas lo hacen razonable: el vaciado es una propiedad del proceso, independiente de los estimadores; el efecto tiene un gradiente con la duración de los vaciados (de +9,8 % a −25,9 %), lo que sugiere un mecanismo y no un azar; la ablación E2c, con las mismas semillas y sin saturación, contrasta ese mecanismo: en esas corridas el filtro pasa a ser mejor (+9,6 %); y reporto también el resultado global, que no favorece al filtro.

Ojo: reconozca que la ablación también se decidió después de ver los datos.

P10. ¿Por qué 100 corridas y por qué un quemado de 300 pasos?

→ Con 100 corridas, los intervalos de las diferencias son de pocos puntos porcentuales. El quemado de 300 pasos excluye el transitorio de la ganancia, que converge a su valor de régimen cerca del paso 202; comprobé que con 60 o 600 pasos las conclusiones no cambian (Tabla 6.7).

4. Resultados e interpretación

P11. En resumen, ¿el filtro es mejor que la regresión local o no?

→ Depende de cómo se mida y de la sintonía. En la corrida típica, sí: gana en el 72 % de las corridas y en el 98 % de las que no tienen vaciado. En promedio, la diferencia no es significativa, porque pierde mucho en las corridas con vaciados largos. Con la sintonía calibrada, gana en casi todas. Reportar solo el promedio habría escondido todo eso.

P12. ¿Por qué el filtro pierde cuando la tolva se vacía?

→ Porque cuando la tolva se vacía la extracción real cae a cero de golpe, y el filtro no lo sabe: se comporta como un lazo de segundo orden con memoria de unos 65,8 s y sigue extrapolando una extracción que ya no ocurre, hasta estimar volúmenes negativos. La regresión local olvida los datos anteriores después de su ventana. La ablación confirma la causa: si se elimina la saturación, con las mismas semillas, el filtro gana en el 97 % de esas corridas. Con $3q_e$ la memoria del filtro baja a unos 50 s y la desventaja desaparece.

P13. ¿Qué significa que el NEES suba a 36,1 en las corridas con vaciado?

→ Que el filtro está sobreconfiado: su error real es mucho mayor que el que declara su covarianza. El valor esperado es 2. Para un gemelo digital es grave, porque la incertidumbre declarada es lo que permite decidir cuándo confiar en la estimación.

P14. ¿Por qué con ruido coloreado el NIS baja en lugar de subir?

→ Porque si el error de medición se parece de un paso al siguiente, el filtro lo sigue como si fuera señal, y la innovación resulta menor de lo que espera. El problema no se ve en la magnitud de la innovación sino en su correlación: la autocorrelación de rezago uno sube hasta 0,94. Por eso hay que monitorear las dos cosas. Y antes de corregir la sintonía hay que comprobar si la autocorrelación responde a q_e: con ruido blanco y ganancia baja, bajó hasta anularse al aumentar q_e; con ruido coloreado casi no cambió, y aumentar q_e desde el valor nominal no redujo apreciablemente el error (con $\rho = 0{,}95$, el RMSE del volumen sube de 8,07 a 9,05 m^3 con $10q_e$). El NIS no separa los dos casos: con $\rho = 0{,}5$ fue 1,047. Con ruido coloreado, lo que corresponde es modelar el ruido.

P15. ¿Por qué no se puede detectar la deriva del sensor?

→ Porque, bajo el modelo del filtro, con un solo sensor un sesgo que crece lentamente es indistinguible de un cambio real. Si agrego al estado el sesgo y su velocidad, la matriz de observabilidad tiene rango 2 de 4. En la práctica, la deriva equivale a un error constante de la tasa, que el filtro absorbe. Para detectarla hace falta redundancia: con una medición de la tasa, por ejemplo el pesómetro de la correa, la velocidad de la deriva se vuelve observable, aunque un sesgo constante no.

Ojo: la objeción fácil es que una tolva vacía tiene volumen 0, y eso permitiría calibrar. Es cierto, pero es información que el modelo del filtro no usa; por eso la afirmación es «bajo el modelo del filtro». Un estimador con la restricción física o con el retorno de la extracción a su nominal podría distinguir la deriva, débilmente; no se evaluó.

P16. ¿Por qué el NIS casi no reacciona al cambio de dureza?

→ Porque el filtro va incorporando el cambio en su estimación de la tasa: el sesgo de su predicción del volumen llega a solo 4,24 m^3, unas 0,4 desviaciones de la innovación. La teoría predice que la media móvil del NIS sube 0,16 sobre su nivel. En la simulación subió 0,13 desde el nivel previo y 0,15 desde el nivel posterior al cambio, que es más bajo porque la tolva se vacía mucho menos. Además, con ese umbral, un filtro perfecto daría una falsa alarma en el 21 % de las corridas en cinco minutos. El cambio se ve en la tasa estimada, no en el NIS.

P17. ¿De dónde sale $\zeta = 1/\sqrt{2}$?

→ De resolver la ecuación de Riccati continua para este modelo: un estado que se integra ($\dot{V} = u - e$), otro que es caminata aleatoria ($\dot{e} = w$) y una medición del primero. Sale una ganancia $[\sqrt{2}\,\omega_n,\ -\omega_n^2]$ y un polinomio característico $s^2 + \sqrt{2}\,\omega_n s + \omega_n^2$, con $\omega_n = (q_e/R\Delta t^2)^{1/4}$. Es un resultado clásico, no mío: el filtro de régimen de un doble integrador tiene polos de Butterworth, y para el filtro α-β Ekstrand (2012) reporta $\zeta \approx 0{,}7$. Lo que hice fue usarlo para explicar y predecir los resultados, y comprobarlo con los autovalores del filtro discreto: $\zeta = 0{,}7071$.

Ojo: esta pregunta separa a quien entiende el filtro de quien lo usa. Practique la deducción en la pizarra (Sección 2.5.3 de la tesis).

P18. ¿Cómo sabe que el código está bien?

→ Por ocho pruebas que el programa ejecuta antes de cualquier experimento y que lo detienen si una falla: covarianza simétrica y definida positiva, ganancia igual a la solución de Riccati calculada con SciPy, error insesgado, NEES y NIS en sus bandas, innovación blanca, invariancia ante escala común, e igualdad entre la versión en línea y la por lotes. Además, dos ejecuciones producen archivos idénticos byte a byte. Esto aporta evidencia, no una demostración: un error que no afectara ninguna de esas propiedades pasaría inadvertido.

5. Proyección

P19. ¿Por qué un filtro de Kalman lineal y no un EKF, un UKF o una red neuronal?

→ Porque la pregunta no era encontrar el mejor estimador, sino entender qué pasa con el estimador más usado cuando sus supuestos fallan. El modelo del proceso es lineal salvo la saturación; un EKF no resuelve una saturación, pero sí un filtro con restricciones o que cambie de modelo, que dejo como trabajo futuro. Una red neuronal necesitaría datos de planta para entrenarse, que no tengo, y haría más difícil atribuir los resultados a causas.

P20. ¿Qué haría con datos reales?

→ Pediría registros de nivel, de despacho de camiones y del pesómetro de la correa. Primero caracterizaría el error del sensor y la frecuencia de vaciados; después identificaría R y q_e, monitorearía el NIS y la autocorrelación de la innovación, y usaría el pesómetro para detectar deriva.

P21. Si no inventó un filtro, ¿cuál es su aporte?

→ La evaluación, no el algoritmo: un módulo verificado y reproducible que se prueba contra un proceso distinto de su modelo, frente a un competidor exigente; la identificación, sugerida por la estratificación y confirmada con una ablación, de la saturación por vaciado como la causa de la desventaja del filtro en este simulador, y de una sintonía calibrada que la compensa; el mapa de qué diagnósticos detectan qué discrepancias, con la

advertencia de que una autocorrelación positiva solo indicó falta de ganancia cuando respondía a la sintonía; y el uso de una aproximación analítica clásica para predecir lo que se simula.

6. Integridad

P22. ¿Qué parte de este trabajo hizo usted y qué parte la inteligencia artificial?

→ Esta pregunta no tiene respuesta modelo, porque la respuesta es un hecho que solo usted conoce. Guía: diga la verdad, en concreto y sin minimizar. Describa qué decidió usted (por ejemplo, aceptar el reencuadre, qué experimentos mantener) y en qué usó la herramienta (programación, verificación de referencias, redacción), en coherencia con la declaración firmada al inicio de la tesis. Lo que la comisión evalúa es que usted entienda y pueda defender cada ecuación, cada decisión y cada línea del código; prepárese para que le pidan explicar cualquier parte en la pizarra o en el computador.

Ojo: no firme ni afirme una autoría exclusiva de lo que no hizo. Si la normativa de la Universidad exige un formato de declaración, úselo.

P23. En el anteproyecto reportó 89,57 % y 98,17 %. ¿Por qué ahora las cifras son otras?

→ Porque la auditoría al comenzar el Proyecto de Título encontró que esas cifras se obtuvieron con datos generados por el mismo modelo del filtro y con una línea base que ignoraba información disponible. Las cifras eran correctas como cálculo, pero no medían lo que parecían medir. El Anexo C documenta cada corrección.

P24. ¿Las referencias existen? ¿Las leyó?

→ Todas se verificaron contra su DOI o la página del editor, y el Anexo A dice qué parte de cada una se leyó. Siendo preciso: de los dos libros de filtro de Kalman en que se apoya el Capítulo 2, Simon y Bar-Shalom, se verificó el índice general (en Simon, también el índice analítico), no los capítulos completos; catorce fuentes se leyeron solo en su resumen y doce se citan solo por sus metadatos, entre ellas las de software y de métodos estadísticos estándar. Las afirmaciones de la tesis se limitan a lo leído, y las propiedades del filtro que uso se comprobaron numéricamente en la verificación EV.

Ojo: mejor aún: antes de la defensa, lea el capítulo 5 de Bar-Shalom (consistencia) y los capítulos 5 y 7 de Simon (filtro discreto, ruido coloreado y restricciones), y actualice el Anexo A.

7. Frases que conviene no decir

- «El filtro está validado industrialmente.» No: solo por simulación.
- «El gemelo digital depura la incertidumbre (Sepasgozar).» La fuente no dice eso; distingue sombra y gemelo por el flujo de datos.
- «Optimizamos la observabilidad.» La observabilidad es una propiedad estructural del modelo; se cumple o no.
- «La ventaja del filtro crece con el ruido.» Solo en promedio, y porque desaparece la desventaja en los vaciados.
- «El NIS detecta cualquier problema.» No detecta el ruido coloreado (baja) ni la deriva.
- «Una autocorrelación positiva significa que falta ganancia.» Solo con ruido blanco; con ruido coloreado también es positiva, y aumentar la ganancia desde la sintonía nominal no reduce el error.
- «El vaciado es la discrepancia que más importa» sin matiz. Diga: la ablación muestra que la saturación explica la desventaja del filtro en este simulador.
- «Deduje que $\zeta = 1/\sqrt{2}$.» Es un resultado clásico; usted lo aplicó y lo comprobó.

- «La tasa de llenado.» El estado es la tasa de *extracción*.
- «Los parámetros vienen de la literatura.» Son supuestos de diseño.